

Databases

GROUP BY

Inhoud

- GROUP BY
 - op één attribuut
 - en SET-functies
 - op meerdere kolommen
 - op expressies
 - en NULL-waarden
 - regels voor SET-functies
- HAVING



GROUP BY

GROUP BY laat toe rijen **te groeperen** op basis van een attribuut.

- Voorbeeld: Groepeer alle rijen in de spelerstabel op basis van gelijke woonplaats.

GROUP BY is vooral interessant samen met het gebruik van **SET-functies**.

- Voorbeeld: Hoeveel spelers wonen er per woonplaats?

GROUP BY op één attribuut

De eenvoudigste vorm van GROUP BY is deze waar **gegroepeerd** wordt op basis van **één kolom** (attribuut).

Voorbeeld: Groepeer alle spelers op basis van hun woonplaats.

```
SELECT plaats  
FROM Tennis.Speler  
GROUP BY plaats;
```

geeft

plaats
Amsterdam
Den Haag
Leiden
Rijswijk
Rotterdam
Voorburg
Zoetermeer

GROUP BY op één attribuut

Werkwijze

- Alle rijen met dezelfde plaats vormen één groep.
- Elke rij in het **tussenresultaat** heeft één waarde in de plaats-kolom. De andere kolommen kunnen meerdere waarden bevatten.

Hoe komen aan het intern tussenresultaat ?

id	naam	voornaam	geboortedatum	geslacht	lidSinds	straat	huisnummer	postcode	plaats	telefoon	bondsnummer
113	Van_Den_Berg	Lydia	1997-10-01	V	2004	Vosseweg	8	1012AB	Amsterdam	018-548745	NULL
2	Elfring	Rudi	1988-09-01	M	2005	Steden	43	3575NH	Den Haag	070-237893	2411
6	Permentier	Raf	1984-06-25	M	2007	Hazensteinln	80	1234KK	Den Haag	070-476537	8467
7	Wijers	Geert-Jan	1983-05-11	M	2001	Erasmusweg	39	9758VB	Den Haag	070-347689	NULL
39	Bischoff	Danny	1986-10-29	M	2000	Ericaplein	78	9629CD	Den Haag	070-393435	NULL
57	Bohemen, van	Marc	1991-08-17	M	2005	Erasmusweg	16	4377CB	Den Haag	070-473458	6409
83	Hofland	Pieter	1976-11-11	M	2002	Mariakade	16a	1812UP	Den Haag	070-353548	1608
100	Permentier	Patrick	1983-02-28	M	1999	Hazensteinln	80	6494SG	Den Haag	070-494593	6524
28	Cools	Carla	1983-06-22	V	2003	Oudegracht	10	1294QK	Leiden	010-659599	NULL
8	Niewenburg	Bertha	1982-07-08	V	2000	Spoorlaan	4	6584WO	Rijswijk	070-458458	2983
44	Bakker, de	Eric	1983-01-09	M	2000	Lawaaistraat	23	4444LJ	Rijswijk	070-368753	1124
112	Baalen, van	Ingrid	1983-10-01	V	2004	Vosseweg	8	6392LK	Rotterdam	010-548745	1319
95	Meuleman	Peter	1983-05-14	M	1992	Hoofdweg	33a	5746OP	Voorburg	070-867564	NULL
27	Cools	Marjan	1984-12-28	V	2003	Liespad	804	8457DK	Zoetermeer	079-234857	2513
104	Moerman	Daniëlla	1990-05-10	V	2004	Stoutlaan	65	9437AO	Zoetermeer	079-987571	7060

plaats	Welke id's
Amsterdam	113
Den Haag	2, 6, 7, 39, 57, 83, 100
Leiden	28
Rijswijk	8,44
Rotterdam	112
Voorburg	95
Zoetermeer	27, 104

GROUP BY op één attribuut

Werkwijze

- Alle rijen met dezelfde plaats vormen één groep.
- Elke rij in het **tussenresultaat** heeft één waarde in de plaats-kolom. De andere kolommen kunnen meerdere waarden bevatten.

Intern tussenresultaat

plaats	Welke id's	...
Amsterdam	113	...
Den Haag	2, 6, 7, 39, 57, 83, 100	...
Leiden	28	...
Rijswijk	8,44	...
Rotterdam	112	...
Voorburg	95	...
Zoetermeer	27, 104	...

Eindresultaat

plaats
Amsterdam
Den Haag
Leiden
Rijswijk
Rotterdam
Voorburg
Zoetermeer

GROUP BY op één attribuut

Hetzelfde resultaat kunnen we ook bereiken met een eenvoudige DISTINCT-opdracht

```
SELECT DISTINCT plaats  
FROM   Tennis.Speler  
ORDER BY plaats;
```

plaats
Amsterdam
Den Haag
Leiden
Rijswijk
Rotterdam
Voorburg
Zoetermeer

Wat is de meerwaarde van GROUP BY?

GROUP BY en SET-functies

SET-functies bij een GROUP BY worden uitgevoerd op elke **gegroepeerde** rij i.p.v. op **alle** rijen.

```
SELECT  
    COUNT(naam) AS 'aantal spelers wonen in ',  
    plaats  
FROM Tennis.Speler  
GROUP BY plaats;
```

aantal spelers wonen in	plaats
1	Amsterdam
7	Den Haag
1	Leiden
2	Rijswijk
1	Rotterdam
1	Voorburg
2	Zoetermeer

GROUP BY en SET-functies

Geef voor elk team het teamnummer, het aantal wedstrijden en het totaal aantal gewonnen sets?

```
SELECT
    teamId,
    COUNT(*)                AS 'aantal wedstrijden',
    SUM(aantalGewonnenSets) AS 'aantal gewonnen sets'
FROM Tennis.Wedstrijd
GROUP BY teamId;
```

id	teamId	spelerId	aantalGewonnenSets	aantalVerlorenSets
1	1	6	3	1
2	1	6	2	3
3	1	6	3	0
4	1	44	3	2
5	1	83	0	3
6	1	2	1	3
7	1	57	3	0
8	1	8	0	3
9	2	27	3	2
10	2	104	3	2
11	2	112	2	3
12	2	112	1	3
13	2	8	0	3

Tussenresultaat, na het groeperen

teamId	id's	aantalGewonnenSets
1	1,2,3,4,5,6,7,8	3,2,3,3,0,1,3,0
2	9,10,11,12,13	3,3,2,1,0

Eindresultaat


teamId	aantal wedstrijden	aantal gewonnen sets
1	8	15
2	5	9

GROUP BY op meerdere kolommen

- Men kan groeperen op **meerdere** kolommen samen.
- De verzameling van deze kolommen **samen** is het groeperingscriterium.
- De volgorde van de kolommen is van geen belang.
- Er is dus **geen sprake van groepering binnen een groepering !!!**

GROUP BY op meerdere kolommen

Geef alle combinaties van teamnummers en spelersnummers uit de wedstrijdental?



Alle rijen met hetzelfde team- en spelersnummer vormen één groep.

GROUP BY op meerdere kolommen

Tussenresultaat na groeperen op de 2 kolommen:

id	teamId	spelerId	aantalGewonnenSets	aantalVerlorenSets
6	1	2	1	3
1	1	6	3	1
2	1	6	2	3
3	1	6	3	0
8	1	8	0	3
4	1	44	3	2
7	1	57	3	0
5	1	83	0	3
13	2	8	0	3
9	2	27	3	2
10	2	104	3	2
11	2	112	2	3
12	2	112	1	3



teamId	spelerId	id	aantalGewonnenSets	aantalVerlorenSets
1	2	6	1	3
1	6	1,2,3	3,2,3	1,3,0
1	8	8	0	3
1	44	4	3	2
1	57	7	3	0
1	83	5	0	3
2	8	13	0	3
2	104	10	3	2
2	112	11,12	1	3

GROUP BY op meerdere kolommen

Tussenresultaat

teamId	spelerId	id	aantalGewonnenSets	aantalVerlorenSets
1	2	6	1	3
1	6	1,2,3	3,2,3	1,3,0
1	8	8	0	3
1	44	4	3	2
1	57	7	3	0
1	83	5	0	3
2	8	13	0	3
2	104	10	3	2
2	112	11,12	1	3



Eindresultaat:

teamId	spelerId
1	2
1	6
1	8
1	44
1	57
1	83
2	8
2	27
2	104
2	112

GROUP BY op meerdere kolommen

Interessanter wordt het wanneer we een aantal SET-functies toevoegen:

```
SELECT
    teamId,
    spelerId,
    COUNT(*)                AS 'aantal wedstrijden',
    SUM(aantalGewonnenSets) AS 'som van gewonnen sets',
    MIN(aantalVerlorenSets) AS 'minimum verloren sets'
FROM Tennis.Wedstrijd
GROUP BY
    teamId,
    spelerId;
```

teamId	spelerId	aantal wedstrijden	aantal gewonnen sets	minimum verloren sets
1	2	1	1	3
1	6	3	8	0
1	8	1	0	3
2	8	1	0	3
2	27	1	3	2
1	44	1	3	2
1	57	1	3	0
1	83	1	0	3
2	104	1	3	2
2	112	2	3	3

Voorbeeld:

Geef id, naam, voornaam en totaalbedrag aan boetes voor elke speler waarvoor ooit een boete werd betaald?

```
SELECT
    S.id,
    S.naam,
    S.voornaam,
    SUM(B.bedrag) AS 'Totale boete'
FROM Tennis.Speler as S INNER JOIN Tennis.Boete as B
    ON S.id = B.spelerId
GROUP BY S.id, S.naam, S.voornaam;
```

id	naam	voornaam	Totale boete
6	Pementier	Raf	100,1234
8	Niewenburg	Bertha	25,0045
27	Cools	Marjan	175,8347
44	Bakker, de	Eric	131,1243
104	Moeman	Daniëlla	50,2345

Voorbeeld

Belangrijk: om de naam en voornaam van de speler te kunnen tonen, moet er ook gegroepeerd worden op naam en voornaam. Fout is dus:

```
SELECT
    S.id,
    S.naam,
    S.voornaam,
    SUM(B.bedrag) AS 'Totale boete'
FROM Tennis.Speler as S INNER JOIN Tennis.Boete as B
    ON S.id = B.spelerId
GROUP BY S.id;
```

Msg 8120, Level 16, State 1, Line 3
Column 'Tennis.Speler.naam' is invalid in the
select list because it is not contained in
either an aggregate function or the GROUP BY
clause.

Groeperen op expressies

We kunnen ook groeperen op basis van expressies i.p.v. op kolommen (attributen).

```
SELECT  
    YEAR(datum) AS 'Jaar',  
    COUNT(*)    AS 'Aantal boetes'  
FROM   Tennis.Boete  
GROUP BY YEAR(datum);
```

Jaar	Aantal boetes
2000	3
2001	1
2002	1
2003	1
2004	2
2019	1

Groeperen van NULL-waarden

Indien men groepeert op basis van een kolom (attribuut) waarvoor NULL-waarden voorkomen, vormen **alle rijen met een NULL-waarde** in deze kolom **samen één groep**.

```
SELECT
    bondsnummer,
    COUNT(id) AS 'aantal spelers'
FROM Tennis.Speler
GROUP BY bondsnummer;
```



bondsnummer	aantal spelers
NULL	5
1124	1
1319	1
1608	1
2411	1
2513	1
2983	1
6409	1
6524	1
7060	1
8467	1

Regels voor SET-functies

Regel 1:

Indien een SELECT-instructie geen GROUP BY omvat, en indien er één of meer SET-functies voorkomen in de SELECT-component, mag een kolom genoemd in de SELECT-component uitsluitend binnen een SET-functie voorkomen.

Voorbeeld:

```
SELECT AVG(bedrag)
FROM   Tennis.Boete;
```

(No column name)

56,369

Regels voor SET-functies

Regel 2:

Indien een SELECT-instructie wel een GROUP BY omvat, mag een kolom genoemd in de SELECT-component uitsluitend binnen een SET-functie, een GROUP BY, of in beiden voorkomen.

```
SELECT
    S.id,
    CONCAT(TRIM(S.voornaam),SPACE(1),TRIM(S.naam)) AS 'Speler',
    SUM(B.bedrag)AS 'Totale boete'
FROM Tennis.Speler as S INNER JOIN Tennis.Boete as B
    ON S.id = B.spelerId
GROUP BY S.id, S.naam, S.voornaam;
```

id	Speler	Totale boete
6	Raf Pementier	100,1234
8	Bertha Niewenburg	25,0045
27	Marjan Cools	175,8347
44	Eric Bakker, de	131,1243
104	Daniëlla Moeman	50,2345

GROUP BY

SET-functie

Zoek de fout ...

```
SELECT  
    plaats,  
    COUNT(*)  
FROM Tennis.Speler  
GROUP BY id;
```

Waarom fout?

- plaats komt in de SELECT-component voor maar niet in een SET-functie of in de GROUP BY
- plaats kan meerdere waarden bevatten, dus deze instructie bevat onverenigbare opdrachten

HAVING

- Met HAVING kunnen rijen geselecteerd worden op basis van **groepseigenschappen**
- HAVING lijkt sterk op WHERE-clause
- HAVING kan zelf **SET-functies bevatten**
(de WHERE-clause kan dit enkel indien hij deel uitmaakt van een subquery)

HAVING: Voorbeeld

Geef voor elke speler voor wie meer dan 120€ boete is betaald, het spelersnummer en het totale boetebedrag?

```
SELECT
    spelerId      AS 'spelersnummer',
    SUM(bedrag)   AS 'totale boetebedrag'
FROM Tennis.Boete
GROUP BY spelerId
HAVING SUM(bedrag) > 120;
```


HAVING: Voorbeeld

Boetes-tabel na groeperen per speler;

id	spelerId	datum	bedrag
1	6	2000-12-08	100.1234 → som = 100.1234
2,5,7	44	2001-05-05, 2000-12-08, 2002-12-30	75.5678 25.5487 → som = 131.1243 30.0078
3,8	27	2003-09-10 2001-11-12	100.789 → som = 175.8347 75.0457
6	8	2004-11-12	25.0045 → som = 25.0045
10	NULL	2019-03-05	25.00 → som = 25

HAVING: Voorbeeld

Tussenresultaat na controle van de HAVING-conditie $\text{SUM}(\text{bedrag}) > 120$

id	spelerId	datum	bedrag
2,5,7	44	2001-05-05, 2000-12-08, 2002-12-30	75.5678 25.5487 → som = 131.243 30.0078
3,8	27	2003-09-10 2001-11-12	100.789 → som = 175.8347 75.0457

Eindresultaat:

spelersnummer	totale boetebedrag
27	175,8347
44	131,1243

HAVING: Regel

Elk attribuut, dat in de HAVING wordt genoemd, mag uitsluitend binnen een SET-functie voorkomen of moet voorkomen in de GROUP BY-component

```
SELECT
    plaats,
    COUNT(*) AS 'Aantal spelers/woonplaats'
FROM Tennis.Speler
GROUP BY plaats
HAVING geboortedatum > '1981-01-18';
```

Msg 8121, Level 16, State 1, Line 6
Column 'Tennis.Speler.geboortedatum' is invalid in the HAVING clause because it is not contained in either an aggregate function or the GROUP BY clause.

Oplossing

- Gebruik WHERE i.p.v. HAVING

geboortedatum hoort in dit voorbeeld niet tot de GROUP BY

```
SELECT
    plaats,
    COUNT(*) AS 'Aantal spelers/woonplaats'
FROM Tennis.Speler
WHERE geboortedatum > '1981-01-18'
GROUP BY plaats;
```

	plaats	Aantal spelers/woonplaats
1	Amsterdam	1
2	Den Haag	6
3	Leiden	1
4	Rijswijk	2
5	Rotterdam	1
6	Voorburg	1
7	Zoetemeer	2

Respecteer de volgorde bij het schrijven van SQL statements!

1. SELECT
2. FROM
3. JOIN
4. WHERE
5. GROUP BY
6. HAVING
7. ORDER BY